

Proiect Pachete Software

Echipa 14: Puiu Andrei/ Negut Adrian, gr. 1093D

1. Pachet software: Python

1.1 Introducere

Acest proiect are ca scop realizarea unei aplicatii interactive in limbajul Python, utilizand platforma Streamlit, pentru analiza calitatii vinului pe baza unor indicatori chimici.

Datele utilizate in cadrul proiectului au fost preluate de pe platforma Kaggle, din datasetul „Wine Quality Dataset”, disponibil la adresa: <https://www.kaggle.com/datasets/yasserh/wine-quality-dataset>.

Aplicatia a fost dezvoltata in Python si rulata local ca mai jos:

Instalare librarii:

```
pip install -r requirements.txt
```

Rulare aplicatie:

```
py -3.10 -m streamlit run app.py
```

Aceasta aplicatie permite explorarea interactiva a datelor, vizualizarea relatiilor dintre variabile si construirea de modele predictive, contribuind astfel la intelegerea factorilor care influenteaza calitatea vinului.

1.2 Functia: `incarca_date()`

Descriere: Incarcarea datelor din fisier CSV

a) Definirea problemei: Incarcarea datasetului

b) Informatii necesare: WineQT.csv

c) Metode: `pd.read_csv()` din pachetul pandas

d) Rezultate: Datele sunt afisate in aplicatie sub forma de tabel

e) Interpretare economica: Permite analiza initiala a datelor si identificarea variabilelor relevante

1. Incarcarea datelor

Fisierul WineQT.csv a fost incarcat cu succes.

Numar randuri

1143

Numar coloane

14

Valori lipsa initiale

0

Primele 5 inregistrari - head()

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality	quality_label	quality_encoded
0	7.4	0.7	0	1.9	0.076	11	34	0.9978	3.51	0.56	9.4	5	Slab	0
1	7.8	0.88	0	2.6	0.098	25	67	0.9968	3.2	0.68	9.8	5	Slab	0
2	7.8	0.76	0.04	2.3	0.092	15	54	0.997	3.26	0.65	9.8	5	Slab	0
3	11.2	0.28	0.56	1.9	0.075	17	60	0.998	3.16	0.58	9.8	6	Slab	0
4	7.4	0.7	0	1.9	0.076	11	34	0.9978	3.51	0.56	9.4	5	Slab	0

1.3 Functia: trateaza_valori_lipsa()

Descriere: Eliminarea valorilor lipsa

- a) Definirea problemei: Valori lipsa
- b) Informatii necesare: Coloane numerice din datasetul WineQT.csv
- c) Metode: isnull() pentru verificarea valorilor lipsa din pachetul pandas
- d) Rezultate: Nu au fost identificate valori lipsa in dataset
- e) Interpretare economica: Asigura obtinerea unor rezultate stabile si corecte in analiza datelor

3. Valori lipsa si valori extreme

Valori lipsa - isnull()

	Coloana	Numar valori lipsa
0	fixed acidity	0
1	volatile acidity	0
2	citric acid	0
3	residual sugar	0
4	chlorides	0
5	free sulfur dioxide	0
6	total sulfur dioxide	0
7	density	0
8	pH	0
9	sulphates	0

Prelucrare aplicata

- valorile lipsa numerice au fost completate cu mediana
- valorile extreme au fost tratate prin metoda IQR
- s-a creat variabila categoriala quality_label

1.4 Functia: trateaza_outlieri()

Descriere: Eliminarea valorilor extreme

a) Definirea problemei: Outlieri

b) Informatii necesare: Distributia datelor din datasetul WineQT.csv

c) Metode: metoda IQR utilizand functii din pachetele pandas si numpy

d) Rezultate: Date curate, fara influenta valorilor extreme

e) Interpretare economica: Permite obtinerea unor rezultate mai realiste in analiza calitatii vinului

Date dupa prelucrare

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality	quality_label	quality_encoded
0	7.4	0.7	0	1.9	0.076	11	34	0.9978	3.51	0.56	9.4	5	Slab	0
1	7.8	0.68	0	2.6	0.098	25	67	0.9968	3.2	0.68	9.8	5	Slab	0
2	7.8	0.76	0.04	2.3	0.092	15	54	0.997	3.26	0.65	9.8	5	Slab	0
3	11.2	0.28	0.56	1.9	0.075	17	60	0.998	3.16	0.58	9.8	6	Slab	0
4	7.4	0.7	0	1.9	0.076	11	34	0.9978	3.51	0.56	9.4	5	Slab	0

1.5 Functia: explorare_date()

Descriere: Statistici descriptive

a) Definirea problemei: Analiza datasetului

b) Informatii necesare: Datele din datasetul WineQT.csv

c) Metode: describe() si dtypes din pachetul pandas

d) Rezultate: Statistici descriptive ale variabilelor

e) Interpretare economica: Permite intelegerea caracteristicilor generale ale datelor si a distributiei acestora

2. Explorare date

Tipuri de date

	Coloana	Tip
3	residual sugar	float64
4	chlorides	float64
5	free sulfur dioxide	float64
6	total sulfur dioxide	float64
7	density	float64
8	pH	float64
9	sulphates	float64
10	alcohol	float64
11	quality	float64
12	quality_label	object

Statistici descriptive

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alco
count	1143	1143	1143	1143	1143	1143	1143	1143	1143	1143	1
mean	8.27	0.5299	0.2683	2.3231	0.0809	15.4633	45.1273	0.9967	3.3101	0.649	10.4
std	1.6302	0.1743	0.1964	0.6096	0.0178	9.7259	29.9748	0.0018	0.1518	0.1365	1.0
min	4.6	0.12	0	0.9	0.04	1	6	0.9922	2.9125	0.33	
25%	7.1	0.3925	0.09	1.9	0.07	7	21	0.9956	3.205	0.55	
50%	7.9	0.52	0.25	2.2	0.079	13	37	0.9967	3.31	0.62	
75%	9.1	0.64	0.42	2.6	0.09	21	61	0.9978	3.4	0.73	
max	12.1	1.0113	0.915	3.65	0.12	42	121	1.0013	3.6925	1	

Exemplu loc / iloc

df.iloc[9:5, 0:4]

	fixed acidity	volatile acidity	citric acid	residual sugar
0		7.4	0.7	1.9
1		7.8	0.88	2.6
2		7.8	0.76	2.3
3		11.2	0.28	1.9
4		7.4	0.7	1.9

1.6 Functia: grupare_date()

Descriere: Grupare si agregare

- a) Definirea problemei: Compararea datelor in functie de nivelul de calitate
- b) Informatii necesare: Variabila quality din datasetul WineQT.csv
- c) Metode: groupby() si mean() din pachetul pandas
- d) Rezultate: Medii ale variabilelor pentru fiecare nivel de calitate
- e) Interpretare economica: Permite compararea caracteristicilor vinurilor in functie de calitate

Obiectiv: analiza caracteristicilor chimice ale vinului si construirea unor modele care explica sau estimeaza nivelul calitatii.

4. Grupare si agregare

Media indicatorilor pe niveluri de calitate

df.groupby("quality").mean(numeric_only=True)

quality	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality_encoded
3.5	8.45	0.8027	0.2127	2.325	0.0802	8.0867	24.5	0.9977	3.3627	0.55	9.8817	9
4	7.797	0.6962	0.1602	2.3742	0.079	14.8485	40.8961	0.9967	3.3894	0.6025	10.2006	9
5	8.1253	0.5834	0.2451	2.3381	0.0841	16.3002	54.3759	0.9971	3.3021	0.6048	9.8994	9
6	8.2868	0.5049	0.2627	2.2837	0.08	15.1231	39.6523	0.9966	3.3219	0.6084	10.6508	9
7	8.7487	0.3937	0.3886	2.45	0.0739	14.4406	35.2169	0.9961	3.2884	0.7381	11.4765	1
7.5	8.775	0.41	0.4325	2.375	0.0702	11.0025	29.375	0.9956	3.2409	0.76	11.9063	1


Numarul observatiilor pe fiecare nivel de calitate

Calitate	Numar observatii
0	3.5
1	4
2	5
3	6
4	7
5	7.5

1.7 Functia: grafice()

Descriere: Vizualizare date

- Definirea problemei: Reprezentarea grafica a datelor
- Informatii necesare: Variabilele din datasetul WineQT.csv
- Metode: functii din pachetul matplotlib, integrate in Streamlit
- Rezultate: Grafice pentru distributia calitatii si relatia dintre variabile
- Interpretare economica: Permite identificarea tendintelor si a relatiilor dintre indicatori



1.8 Etapa: codificare_date()

Descriere: Codificare variabile

- a) Definirea problemei: Transformarea variabilei quality in format categorial si numeric
- b) Informatii necesare: Variabila quality din datasetul WineQT.csv
- c) Metode: np.where() din pachetul numpy si map() din pachetul pandas
- d) Rezultate: Date codificate in variabilele quality_label si quality_encoded
- e) Interpretare economica: Permite separarea vinurilor in functie de calitate si utilizarea lor in modele predictive

1. Incarcarea datelor

Fisierul WineQT.csv a fost incarcat cu succes.

Numar randuri

1143

Numar coloane

14

Valori lipsa initiale

0

Primele 5 inregistrari - head()

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality	quality_label	quality_encoded
0	7.4	0.7	0	1.9	0.076	11	34	0.9978	3.51	0.56	9.4	5	Slab	0
1	7.8	0.88	0	2.6	0.098	25	67	0.9968	3.2	0.68	9.8	5	Slab	0
2	7.8	0.76	0.04	2.3	0.092	15	54	0.997	3.26	0.65	9.8	5	Slab	0
3	11.2	0.28	0.56	1.9	0.075	17	60	0.998	3.16	0.58	9.8	6	Slab	0
4	7.4	0.7	0	1.9	0.076	11	34	0.9978	3.51	0.56	9.4	5	Slab	0

1.9 Etapa: scalare_date()

Descriere: Normalizare date

- a) Definirea problemei: Scalarea variabilelor numerice
- b) Informatii necesare: Variabilele numerice din datasetul WineQT.csv
- c) Metode: StandardScaler() din pachetul scikit-learn
- d) Rezultate: Date scalate, cu valori normalizate
- e) Interpretare economica: Permite compararea corecta intre variabile si imbunatateste performanta modelelor predictive

Scalarea datelor

```
scaler = StandardScaler()  
X_scaled = scaler.fit_transform(X)
```

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide
0	-0.5339	0.9766	-1.3665	-0.6944	-0.2776	-0.4591	-0.371
1	-0.2884	2.0099	-1.3665	0.4544	0.9622	0.981	0.7
2	-0.2884	1.321	-1.1627	-0.038	0.6241	-0.0477	0.296
3	1.7981	-1.4345	1.4857	-0.6944	-0.3339	0.1581	0.496
4	-0.5339	0.9766	-1.3665	-0.6944	-0.2776	-0.4591	-0.371

1.10 Functia: `sectiune_clasificare()`

Descriere: Clasificare vinuri

- a) Definirea problemei: Predictia calitatii vinurilor
- b) Informatii necesare: Datele scalate si variabila `quality_encoded` din datasetul `WineQT.csv`
- c) Metode: `LogisticRegression()` din pachetul `scikit-learn`
- d) Rezultate: Acuratetea modelului si matricea de confuzie
- e) Interpretare economica: Permite clasificarea vinurilor in functie de calitate si sprijina luarea deciziilor privind controlul calitatii

Obiectiv: analiza caracteristicilor chimice ale vinului si construirea unor modele care explica sau estimeaza nivelul calitatii.

6. Clasificare - Regresie logistica

Acuratete

Accuracy

86.46%

Scalarea datelor

```
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol
0	-0.5339	0.9766	-1.3665	-0.6944	-0.2776	-0.4591	-0.3714	0.5836	1.3175	-0.6524	-0.9716
1	-0.2884	2.0099	-1.3665	0.4544	0.9622	0.981	0.73	0.0408	-0.7257	0.2273	-0.5971
2	-0.2884	1.321	-1.1627	-0.038	0.6241	-0.0477	0.2961	0.1493	-0.3302	0.0074	-0.5971
3	1.7981	-1.4345	1.4857	-0.6944	-0.3339	0.1581	0.4964	0.6921	-0.9894	-0.5058	-0.5971
4	-0.5339	0.9766	-1.3665	-0.6944	-0.2776	-0.4591	-0.3714	0.5836	1.3175	-0.6524	-0.9716

Raport de clasificare

precision recall f1-score support

```
0    0.90  0.95  0.92   197
1    0.53  0.31  0.39    32
```

```
accuracy          0.86   229
macro avg   0.71  0.63  0.66   229
weighted avg  0.84  0.86  0.85   229
```

1.11 Functia: sectiune_regresie()

Descriere: Regresie multipla

- Definirea problemei: Determinarea influentei variabilelor asupra calitatii vinului
- Informatii necesare: Variabilele numerice si variabila quality din datasetul WineQT.csv
- Metode: OLS() din pachetul statsmodels
- Rezultate: Coeficientii modelului si indicatori statistici (R-squared, p-values)
- Interpretare economica: Permite identificarea factorilor care influenteaza calitatea vinului si sprijina optimizarea procesului de productie

7. Regresie multipla - Statsmodels

Rezumatul modelului

OLS Regression Results

```
=====
Dep. Variable:      quality  R-squared:      0.389
Model:              OLS     Adj. R-squared:    0.383
Method:             Least Squares  F-statistic: 65.55
Date:               Sun, 19 Apr 2026  Prob (F-statistic): 5.19e-113
Time:               14:03:06  Log-Likelihood: -1054.5
No. Observations:   1143  AIC:                2133.
Df Residuals:       1131  BIC:                2194.
Df Model:            11
Covariance Type:    nonrobust
=====

               coef  std err      t  P>|t|  [0.025   0.975]
-----
const          27.3774   26.252    1.043  0.297  -24.132   78.886
fixed acidity    0.0467    0.030    1.530  0.126  -0.013    0.106
volatile acidity -1.0968    0.138  -7.971  0.000  -1.367   -0.827
citric acid     -0.3131    0.160  -1.952  0.051  -0.628    0.002
residual sugar   0.0263    0.042    0.627  0.531  -0.056    0.109
chlorides       -2.2665    1.184  -1.915  0.056  -4.589    0.056
free sulfur dioxide 0.0032    0.003    1.207  0.228  -0.002    0.008
total sulfur dioxide -0.0029    0.001  -3.208  0.001  -0.005   -0.001
density        -23.7546   26.795  -0.887  0.376  -76.328   28.819
pH             -0.3421    0.216  -1.585  0.113  -0.766    0.081
sulphates        1.1953    0.153    7.813  0.000    0.895    1.495
alcohol          0.2676    0.032    8.364  0.000    0.205    0.330
=====
```

```
=====
Omnibus:          10.150  Durbin-Watson:      1.776
Prob(Omnibus):    0.006  Jarque-Bera (JB):    10.746
Skew:             -0.183  Prob(JB):            0.00464
Kurtosis:         3.303  Cond. No.            1.20e+05
=====
```

2. Pachet software: SAS

2.1 Introducere

Pentru implementarea aceleiasi analize in SAS, a fost dezvoltata o aplicatie utilizand platforma SAS Studio si instrumentele oferite de SAS OnDemand for Academics.

Datele utilizate au fost preluate din acelasi dataset „Wine Quality Dataset”, disponibil pe platforma Kaggle la adresa: <https://www.kaggle.com/datasets/yasserh/wine-quality-dataset>.

Fisierul WineQT.csv a fost incarcat in SAS Studio, iar scriptul SAS a fost rulat din fisierul: app.sas

Aplicatia dezvoltata in SAS permite importarea si prelucrarea datelor, realizarea de statistici descriptive, reprezentari grafice si modele predictive, contribuind astfel la analiza factorilor care influenteaza calitatea vinului.

2.2 Procedura: PROC IMPORT

Descriere: Importarea datelor din fisier CSV

- a) Definirea problemei: Incarcarea datasetului WineQT.csv in SAS pentru a putea fi analizat si prelucrat.
- b) Informatii necesare: Fisierul WineQT.csv si calea acestuia in SAS Studio.
- c) Metode: Se utilizeaza procedura PROC IMPORT, cu optiunile datafile, out, dbms=csv, replace, guessingrows=max si getnames=yes.
- d) Rezultate: A fost creat setul de date SAS wine_raw, care contine 1143 observatii si 13 variabile.
- e) Interpretare economica: Importarea datelor permite analiza indicatorilor chimici ai vinurilor si reprezinta primul pas pentru evaluarea factorilor care influenteaza calitatea acestora.

2.3 Procedura: PROC CONTENTS

Descriere: Afisarea structurii setului de date

- a) Definirea problemei: Verificarea structurii datasetului importat si a variabilelor existente.
- b) Informatii necesare: Setul de date wine_raw obtinut dupa importarea fisierului WineQT.csv.
- c) Metode: Se utilizeaza procedura PROC CONTENTS pentru afisarea informatiilor despre structura setului de date.
- d) Rezultate: Sunt afisate numarul de observatii, numarul de variabile, tipul acestora si alte informatii despre dataset.
- e) Interpretare economica: Cunoasterea structurii datelor este importanta pentru intelegerea indicatorilor analizati si pentru alegerea metodelor potrivite de prelucrare si analiza a datelor.

Structura setului de date WineQT

The CONTENTS Procedure

Data Set Name	WORK.WINE_RAW	Observations	1143
Member Type	DATA	Variables	13
Engine	V9	Indexes	0
Created	16.05.2026 11:07:31	Observation Length	104
Last Modified	16.05.2026 11:07:31	Deleted Observations	0
Protection		Compressed	NO
Data Set Type		Sorted	NO
Label			
Data Representation	SOLARIS_X86_64, LINUX_X86_64, ALPHA_TRU64, LINUX_IA64		
Encoding	utf-8 Unicode (UTF-8)		

2.4 Procedura: PROC PRINT

Descriere: Afisarea primelor observatii din setul de date

- Definirea problemei: Vizualizarea datelor importate pentru verificarea corectitudinii acestora.
- Informatii necesare: Setul de date wine_raw obtinut dupa importarea fisierului WineQT.csv.
- Metode: Se utilizeaza procedura PROC PRINT cu optiunea obs=10 pentru afisarea primelor 10 observatii.
- Rezultate: Sunt afisate primele inregistrari din dataset, impreuna cu valorile variabilelor analizate.
- Interpretare economica: Vizualizarea datelor permite identificarea indicatorilor relevanti pentru analiza calitatii vinului si verificarea corectitudinii datelor importate.

Primele 10 observatii din setul de date

Obs	fixed_acidity	volatile_acidity	citric_acid	residual_sugar	chlorides	free_sulfur_dioxide	total_sulfur_dioxide	density	pH	sulphates	alcohol	quality	Id
1	7.4	0.7	0	1.9	0.076	11	34	0.9978	3.51	0.56	9.4	5	0
2	7.8	0.88	0	2.6	0.098	25	67	0.9968	3.2	0.68	9.8	5	1
3	7.8	0.76	0.04	2.3	0.092	15	54	0.997	3.26	0.65	9.8	5	2
4	11.2	0.28	0.56	1.9	0.075	17	60	0.998	3.16	0.58	9.8	6	3
5	7.4	0.7	0	1.9	0.076	11	34	0.9978	3.51	0.56	9.4	5	4
6	7.4	0.66	0	1.8	0.075	13	40	0.9978	3.51	0.56	9.4	5	5
7	7.9	0.6	0.06	1.6	0.069	15	59	0.9964	3.3	0.46	9.4	5	6
8	7.3	0.65	0	1.2	0.065	15	21	0.9946	3.39	0.47	10	7	7
9	7.8	0.58	0.02	2	0.073	9	18	0.9968	3.36	0.57	9.5	7	8
10	6.7	0.58	0.08	1.8	0.097	15	65	0.9959	3.28	0.54	9.2	5	10

2.5 Procedura: PROC MEANS

Descriere: Calcularea statisticilor descriptive si verificarea valorilor lipsa

- Definirea problemei: Analiza variabilelor numerice si verificarea existentei valorilor lipsa in dataset.
- Informatii necesare: Variabilele numerice din setul de date wine_raw.
- Metode: Se utilizeaza procedura PROC MEANS cu indicatorii n, nmiss, mean, median, min, max si std.

d) Rezultate: Sunt calculate statistici descriptive precum media, mediana, minimul, maximul si abaterea standard pentru variabilele numerice analizate.

e) Interpretare economica: Statisticile descriptive permit intelegerea distributiei indicatorilor chimici si identificarea variabilelor care pot influenta calitatea vinului.

Statistici descriptive si valori lipsa

The MEANS Procedure

Variable	N	N Miss	Mean	Median	Minimum	Maximum	Std Dev
fixed_acidity	1143	0	8.3111111	7.9000000	4.6000000	15.9000000	1.7475950
volatile_acidity	1143	0	0.5313388	0.5200000	0.1200000	1.5800000	0.1796332
citric_acid	1143	0	0.2683640	0.2500000	0	1.0000000	0.1966859
residual_sugar	1143	0	2.5321522	2.2000000	0.9000000	15.5000000	1.3559175
chlorides	1143	0	0.0869326	0.0790000	0.0120000	0.6110000	0.0472673
free_sulfur_dioxide	1143	0	15.6154856	13.0000000	1.0000000	68.0000000	10.2504861
total_sulfur_dioxide	1143	0	45.9146982	37.0000000	6.0000000	289.0000000	32.7821303
density	1143	0	0.9967304	0.9966800	0.9900700	1.0036900	0.0019251
pH	1143	0	3.3110149	3.3100000	2.7400000	4.0100000	0.1566641
sulphates	1143	0	0.6577078	0.6200000	0.3300000	2.0000000	0.1703987
alcohol	1143	0	10.4421114	10.2000000	8.4000000	14.9000000	1.0821956
quality	1143	0	5.6570429	6.0000000	3.0000000	8.0000000	0.8058242
id	1143	0	804.9693788	794.0000000	0	1597.00	463.9971163

2.6 Procedura: PROC FORMAT

Descriere: Crearea formatelor definite de utilizator

a) Definirea problemei: Transformarea valorilor numerice ale calitatii in categorii mai usor de interpretat.

b) Informatii necesare: Variabilele quality si quality_encoded din setul de date wine_clean.

c) Metode: Se utilizeaza procedura PROC FORMAT pentru definirea formatelor calitate_fmt si bun_fmt.

d) Rezultate: Valorile calitatii sunt grupate in categoriile „Slab/mediu” si „Bun”.

e) Interpretare economica: Gruparea vinurilor in categorii permite o interpretare mai clara a nivelului de calitate si faciliteaza analiza comparativa intre diferitele tipuri de vinuri.

Aceasta procedura nu genereaza direct un rezultat tabelar sau grafic in fereastra Results. Formatele definite sunt utilizate ulterior in cadrul prelucrarii datelor si pot fi observate in rezultatele generate de procedurile PROC PRINT, PROC FREQ si PROC SGPLOT.

2.7 Etapa: DATA step

Descriere: Prelucrarea datelor si crearea de variabile noi

a) Definirea problemei: Pregatirea datelor pentru analiza si modelare prin crearea unor variabile suplimentare si tratarea valorilor lipsa.

b) Informatii necesare: Setul de date wine_raw si variabilele numerice din dataset.

c) Metode: Se utilizeaza DATA step, array, functia missing(), instructiuni IF/ELSE si functia put() pentru crearea noilor variabile.

d) Rezultate: A fost creat setul de date wine_clean, iar variabilele quality_encoded, quality_label, quality_binara si alcohol_class au fost generate cu succes.

e) Interpretare economica: Prelucrarea datelor permite clasificarea vinurilor in categorii de calitate si pregatirea datasetului pentru analize statistice si modele predictive.

Aceasta etapa reprezinta o prelucrare interna a datelor si nu genereaza direct un rezultat tabelar sau grafic in fereastra Results. Efectele transformarilor realizate pot fi observate ulterior in rezultatele generate prin procedura PROC PRINT aplicata asupra setului de date wine_clean.

2.8 Procedura: PROC PRINT dupa prelucrare

Descriere: Afisarea primelor observatii dupa prelucrarea datelor

a) Definirea problemei: Verificarea noilor variabile create in setul de date wine_clean.

b) Informatii necesare: Setul de date wine_clean si variabilele Id, alcohol, volatile_acidity, sulphates, quality, quality_label, quality_encoded, quality_binara si alcohol_class.

c) Metode: Se utilizeaza procedura PROC PRINT cu optiunea obs=10 si instructiunea var pentru afisarea variabilelor relevante.

d) Rezultate: Sunt afisate primele 10 observatii dupa prelucrare, inclusiv variabilele nou create pentru clasificarea vinurilor.

e) Interpretare economica: Afisarea datelor prelucrate permite verificarea clasificarii vinurilor in categorii de calitate si pregatirea datelor pentru analizele statistice si predictive urmatoare.

Primele 10 observatii dupa prelucrare

Obs	Id	alcohol	volatile_acidity	sulphates	quality	quality_label	quality_encoded	quality_binara	alcohol_class
1	0	9.4	0.7	0.56	5	Slab/mediu	0	Slab/mediu	Alcool scazut
2	1	9.8	0.88	0.68	5	Slab/mediu	0	Slab/mediu	Alcool scazut
3	2	9.8	0.76	0.65	5	Slab/mediu	0	Slab/mediu	Alcool scazut
4	3	9.8	0.28	0.58	6	Bun	1	Bun	Alcool scazut
5	4	9.4	0.7	0.56	5	Slab/mediu	0	Slab/mediu	Alcool scazut
6	5	9.4	0.66	0.56	5	Slab/mediu	0	Slab/mediu	Alcool scazut
7	6	9.4	0.6	0.46	5	Slab/mediu	0	Slab/mediu	Alcool scazut
8	7	10	0.65	0.47	7	Bun	1	Bun	Alcool mediu
9	8	9.5	0.58	0.57	7	Bun	1	Bun	Alcool scazut
10	10	9.2	0.58	0.54	5	Slab/mediu	0	Slab/mediu	Alcool scazut

2.9 Etapa: Crearea subseturilor de date

Descriere: Separarea vinurilor in functie de categoria de calitate

a) Definirea problemei: Impartirea datasetului in doua subseturi distincte: vinuri bune si vinuri slabe/medii.

b) Informatii necesare: Variabila `quality_encoded` din setul de date `wine_clean`.

c) Metode: Se utilizeaza `DATA` step si instructiuni `IF/ELSE` impreuna cu instructiunea `output` pentru generarea subseturilor `vinuri_bune` si `vinuri_slabe_medii`.

d) Rezultate: Au fost create doua subseturi de date:

- `vinuri_bune`, cu 621 observatii;

- `vinuri_slabe_medii`, cu 522 observatii.

Valorile au fost obtinute din logul SAS dupa executia codului.

e) Interpretare economica: Separarea vinurilor dupa calitate permite analiza comparativa a caracteristicilor chimice si identificarea factorilor asociati vinurilor considerate bune.

Aceasta etapa reprezinta o prelucrare interna a datelor si nu genereaza direct un rezultat tabelar sau grafic in fereastra Results. Rezultatele separarii pe categorii pot fi observate ulterior in cadrul procedurii `PROC FREQ`.

2.10 Procedura: PROC FREQ

Descriere: Analiza frecventelor pe categorii de calitate

a) Definirea problemei: Determinarea numarului de vinuri din fiecare categorie de calitate.

b) Informatii necesare: Variabilele `quality_label`, `quality_encoded` si `quality_binara` din setul de date `wine_clean`.

c) Metode: Se utilizeaza procedura `PROC FREQ` cu instructiunea `tables` pentru calcularea frecventelor fiecarei categorii.

d) Rezultate: Sunt afisate frecventele pentru categoriile de calitate ale vinurilor.

e) Interpretare economica: Analiza frecventelor permite observarea distributiei vinurilor in functie de calitate si evaluarea proportiei vinurilor considerate bune fata de cele slabe sau medii.

Numar de observatii pe categorii de calitate

The FREQ Procedure

quality_label	Frequency	Percent
Bun	621	54.33
Slab/mediu	522	45.67

quality_encoded	Frequency	Percent
0	522	45.67
1	621	54.33

quality_binara	Frequency	Percent
Bun	621	54.33
Slab/mediu	522	45.67

2.11 Procedura: PROC MEANS cu CLASS

Descriere: Calcularea indicatorilor statistici pe categorii de calitate

a) Definirea problemei: Compararea valorilor medii ale indicatorilor chimici pentru vinurile bune si vinurile slabe/medii.

b) Informatii necesare: Variabilele alcohol, volatile_acidity, citric_acid, sulphates, density, pH si quality_label din setul de date wine_clean.

c) Metode: Se utilizeaza procedura PROC MEANS cu optiunea CLASS pentru gruparea observatiilor in functie de categoria de calitate.

d) Rezultate: Sunt calculate statistici descriptive precum media, mediana, minimul, maximul si abaterea standard pentru fiecare categorie de vinuri.

e) Interpretare economica: Compararea indicatorilor statistici intre categoriile de vinuri permite identificarea caracteristicilor asociate vinurilor considerate de calitate mai buna.

Indicatori medii pe categorii de calitate

The MEANS Procedure

quality_label	N Obs	Variable	Mean	Median	Minimum	Maximum	Std Dev
Bun	621	alcohol	10.879	10.800	8.400	14.000	1.109
		volatile_acidity	0.477	0.470	0.120	1.040	0.161
		citric_acid	0.296	0.310	0.000	0.760	0.203
		sulphates	0.694	0.660	0.390	1.950	0.161
		density	0.996	0.996	0.990	1.004	0.002
		pH	3.313	3.310	2.860	4.010	0.158
Slab/mediu	522	alcohol	9.923	9.700	8.400	14.900	0.777
		volatile_acidity	0.596	0.590	0.180	1.580	0.179
		citric_acid	0.235	0.220	0.000	1.000	0.184
		sulphates	0.614	0.570	0.330	2.000	0.171
		density	0.997	0.997	0.993	1.003	0.002
		pH	3.308	3.300	2.740	3.900	0.155

2.12 Procedura: PROC SQL

Descriere: Analiza datelor prin interogari SQL

- Definirea problemei: Calcularea unor indicatori agregati pentru fiecare nivel de calitate al vinurilor.
- Informatii necesare: Variabilele quality, alcohol, volatile_acidity si sulphates din setul de date wine_clean.
- Metode: Se utilizeaza procedura PROC SQL impreuna cu functiile count() si mean(), precum si instructiunile GROUP BY si ORDER BY.
- Rezultate: Sunt obtinute numarul de observatii si valorile medii ale principalilor indicatori pentru fiecare nivel de calitate.
- Interpretare economica: Interogarile SQL permit compararea rapida a grupelor de vinuri si identificarea caracteristicilor asociate diferitelor niveluri de calitate.

Analiza prin PROC SQL - medii pe niveluri de calitate

quality	Numar_observatii	Alcool_meniu	Aciditate_volatila_medie	Sulfati_medii
3	6	9.692	0.898	0.550
4	33	10.261	0.700	0.638
5	483	9.902	0.585	0.613
6	462	10.655	0.505	0.677
7	143	11.483	0.394	0.744
8	16	11.938	0.410	0.766

2.13 Procedura: PROC SQL cu OUTOBS

Descriere: Selectarea celor mai bune vinuri dupa calitate si nivelul alcoolului

- Definirea problemei: Identificarea vinurilor cu cele mai ridicate valori ale calitatii si alcoolului.

b) Informatii necesare: Variabilele Id, alcohol, volatile_acidity, sulphates, quality si quality_label din setul de date wine_clean.

c) Metode: Se utilizeaza procedura PROC SQL cu instructiunea ORDER BY quality desc, alcohol desc si optiunea outobs=10 pentru limitarea numarului de rezultate afisate.

d) Rezultate: Sunt afisate primele 10 vinuri ordonate descrescator dupa calitate si nivelul alcoolului.

e) Interpretare economica: Selectarea vinurilor cu cele mai bune caracteristici poate contribui la identificarea produselor cu potential comercial ridicat si la analiza factorilor asociati vinurilor de calitate superioara.

Cele mai bune vinuri dupa calitate si alcool

Id	alcohol	volatile_acidity	sulphates	quality	quality_label
588	14	0.42	0.74	8	Bun
455	13.4	0.62	0.69	8	Bun
1120	13.1	0.54	0.72	8	Bun
390	12.9	0.85	0.82	8	Bun
267	12.8	0.35	0.86	8	Bun
278	12.6	0.32	0.82	8	Bun
1061	12.5	0.4	0.69	8	Bun
1090	11.8	0.26	0.63	8	Bun
481	11.7	0.3	0.92	8	Bun
1202	11.7	0.42	0.69	8	Bun

2.14 Procedura: PROC SGPLOT - distributia calitatii vinurilor

Descriere: Reprezentarea grafica a distributiei calitatii vinurilor


a) Definirea problemei: Vizualizarea numarului de vinuri pentru fiecare nivel de calitate.

b) Informatii necesare: Variabila quality din setul de date wine_clean.

c) Metode: Se utilizeaza procedura PROC SGPLOT cu un grafic de tip VBAR pentru reprezentarea distributiei calitatii vinurilor.

d) Rezultate: Este generat un grafic care afiseaza numarul observatiilor pentru fiecare nivel de calitate.


e) Interpretare economica: Graficul permite observarea nivelurilor de calitate predominante si ofera o imagine generala asupra distributiei vinurilor analizate.



2.15 Procedura: PROC SGPLOT - relatia dintre alcool si calitatea vinului

Descriere: Analiza relatiei dintre nivelul alcoolului si calitatea vinului


- Definirea problemei: Reprezentarea grafica a legaturii dintre continutul de alcool si calitatea vinului.
- Informatii necesare: Variabilele alcohol, quality si quality_label din setul de date wine_clean.
- Metode: Se utilizeaza procedura PROC SGPLOT cu un grafic de tip scatterplot si o linie de regresie generata prin instructiunea REG.
- Rezultate: Este generat un grafic care evidentiaza relatia dintre nivelul alcoolului si calitatea vinului.
- Interpretare economica: Graficul permite observarea tendintei dintre continutul de alcool si calitatea vinului. Vinurile cu un nivel mai ridicat al alcoolului tind sa fie asociate cu o calitate mai buna.



2.16 Procedura: PROC SGPLOT - relatia dintre aciditatea volatila si calitatea vinului

Descriere: Analiza relatiei dintre aciditatea volatila si calitatea vinului


- Definirea problemei: Reprezentarea grafica a legaturii dintre aciditatea volatila si calitatea vinului.
- Informatii necesare: Variabilele volatile_acidity, quality si quality_label din setul de date wine_clean.
- Metode: Se utilizeaza procedura PROC SGPLOT cu un grafic de tip scatterplot si o linie de regresie generata prin instructiunea REG.
- Rezultate: Este generat un grafic care evidentiaza relatia dintre aciditatea volatila si calitatea vinului.
- Interpretare economica: Graficul permite observarea tendintei dintre aciditatea volatila si calitatea vinului. Valorile mai ridicate ale aciditatii volatile tind sa fie asociate cu vinuri de calitate mai scazuta.



2.17 Procedura: PROC LOGISTIC

Descriere: Clasificarea vinurilor bune prin regresie logistica

- Definirea problemei: Estimarea probabilitatii ca un vin sa fie incadrat in categoria „Bun”.
- Informatii necesare: Variabila `quality_encoded` si variabilele `alcohol`, `volatile_acidity`, `sulphates`, `citric_acid`, `density` si `pH` din setul de date `wine_clean`.
- Metode: Se utilizeaza procedura PROC LOGISTIC pentru construirea unui model de clasificare binara. Modelul estimeaza probabilitatea ca variabila `quality_encoded` sa aiba valoarea 1.
- Rezultate: Modelul logistic a fost generat cu succes, iar pentru fiecare observatie a fost calculata probabilitatea estimata ca vinul sa fie considerat bun.
- Interpretare economica: Regresia logistica permite identificarea factorilor care influenteaza probabilitatea ca un vin sa fie de calitate buna si poate sprijini procesul de evaluare si selectie a produselor.



Curba ROC este un grafic utilizat pentru evaluarea performantei modelului de clasificare. Aceasta arata cat de bine poate modelul sa diferentieze vinurile bune de cele slabe sau medii. Valoarea AUC = 0.8212 indica faptul ca modelul logistic are o performanta buna de clasificare.

2.18 Procedura: PROC PRINT pentru predictii

Descriere: Afisarea predictiilor generate de modelul logistic

- a) Definirea problemei: Vizualizarea probabilitatilor estimate de modelul logistic pentru fiecare vin.
- b) Informatii necesare: Setul de date wine_predictii si variabila probabilitate_vin_bun.
- c) Metode: Se utilizeaza procedura PROC PRINT cu optiunea obs=10 pentru afisarea primelor predictii generate de model.
- d) Rezultate: Sunt afisate primele 10 observatii impreuna cu probabilitatea estimata ca vinul sa fie considerat bun.
- e) Interpretare economica: Probabilitatea estimata permite evaluarea fiecarui vin si poate contribui la identificarea produselor cu potential ridicat de calitate.

Primele 10 predictii generate de modelul logistic

Obs	Id	alcohol	volatile_acidity	sulphates	quality	quality_label	quality_encoded	probabilitate_vin_bun
1	0	9.4	0.7	0.56	5	Slab/mediu	0	0.21150
2	1	9.8	0.88	0.68	5	Slab/mediu	0	0.23262
3	2	9.8	0.76	0.65	5	Slab/mediu	0	0.29688
4	3	9.8	0.28	0.58	6	Bun	1	0.52171
5	4	9.4	0.7	0.56	5	Slab/mediu	0	0.21150
6	5	9.4	0.66	0.56	5	Slab/mediu	0	0.24197
7	6	9.4	0.6	0.46	5	Slab/mediu	0	0.22350
8	7	10	0.65	0.47	7	Bun	1	0.29079
9	8	9.5	0.58	0.57	7	Bun	1	0.33447
10	10	9.2	0.58	0.54	5	Slab/mediu	0	0.21673

2.19 Procedura: PROC REG

Descriere: Regresie liniara multipla pentru analiza calitatii vinului

- Definirea problemei: Determinarea influentei indicatorilor chimici asupra calitatii vinului.
- Informatii necesare: Variabila dependenta quality si variabilele explicative alcohol, volatile_acidity, sulphates, citric_acid, density si pH din setul de date wine_clean.
- Metode: Se utilizeaza procedura PROC REG pentru construirea unui model de regresie liniara multipla.
- Rezultate: Sunt obtinuti coeficientii modelului si indicatorii statistici necesari pentru evaluarea influentei variabilelor asupra calitatii vinului.
- Interpretare economica: Regresia liniara multipla permite identificarea factorilor care influenteaza calitatea vinului si poate contribui la optimizarea procesului de productie si imbunatatirea caracteristicilor produsului final.

Regresie liniara multipla - influenta indicatorilor asupra calitatii

The REG Procedure
Model: MODEL1
Dependent Variable: quality

Number of Observations Read	1143
Number of Observations Used	1143

Analysis of Variance					
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F
Model	8	286.08672	44.34779	105.96	<.0001
Error	1136	475.47408	0.41855		
Corrected Total	1142	741.56080			

Root MSE	0.64696	R-Square	0.3588
Dependent Mean	5.65704	Adj R-Sq	0.3554
Coeff Var	11.43628		

Parameter Estimates					
Variable	DF	Parameter Estimate	Standard Error	t Value	Pr > t
Intercept	1	-9.68482	13.63713	-0.71	0.4777
alcohol	1	0.34079	0.02291	14.87	<.0001
volatile_acidity	1	-1.34534	0.13390	-10.05	<.0001
sulphates	1	0.64292	0.12076	5.32	<.0001
citric_acid	1	-0.33295	0.15719	-2.12	0.0344
density	1	13.85601	13.59720	1.02	0.3084
pH	1	-0.49714	0.15551	-3.20	0.0014

3. Concluzii

In cadrul proiectului au fost utilizate atat Python, cat si SAS pentru analiza calitatii vinului pe baza unor indicatori chimici. Prin intermediul acestor pachete software au fost realizate importarea si prelucrarea datelor, analiza statistica, reprezentari grafice si modele predictive.

Rezultatele obtinute au evidentiat existenta unor relatii intre anumiti indicatori chimici si calitatea vinului. De exemplu, un continut mai ridicat de alcool tinde sa fie asociat cu vinuri de calitate mai buna, in timp ce valori mari ale aciditatii volatile sunt asociate cu vinuri de calitate mai scazuta.

Modelele de regresie si clasificare utilizate au demonstrat faptul ca datele pot fi analizate eficient cu ajutorul instrumentelor oferite de SAS si Python. Aplicatiile realizate permit intelegerea mai buna a factorilor care influenteaza calitatea vinului si pot constitui un exemplu de utilizare a tehnicilor de analiza a datelor in domeniul economic si al industriei alimentare.

Comparativ cu implementarea realizata in Python, varianta dezvoltata in SAS este orientata mai mult spre analiza statistica si utilizarea procedurilor specifice pentru prelucrarea si modelarea datelor. In schimb, aplicatia dezvoltata in Python ofera un nivel mai ridicat de interactivitate prin intermediul platformei Streamlit si faciliteaza integrarea tehnicilor moderne de analiza si machine learning.

Implementarea in Python a evidentiat avantajele explorarii interactive a datelor si ale reprezentarilor grafice intuitive, in timp ce varianta SAS a pus accent pe analiza statistica detaliata, rapoarte structurate si evaluarea performantelor modelelor prin indicatori precum curba ROC si coeficientii de regresie.

Utilizarea ambelor pachete software a permis realizarea aceleiasi analize prin abordari diferite si evidentierea avantajelor oferite de fiecare tehnologie.