Proiect Pachete Software
Echipa 14: Puiu Andrei/ Negut Adrian, gr. 1093D

1. Pachet software: Python

1.1 Introducere

Acest proiect are ca scop realizarea unei aplicatii interactive in limbajul Python, utilizand platforma Streamlit, pentru analiza calitatii vinului pe baza unor indicatori chimici.

Datele utilizate in cadrul proiectului au fost preluate de pe platforma Kaggle, din datasetul „Wine Quality Dataset", disponibil la adresa: https://www.kaggle.com/datasets/yasserh/wine-quality-dataset.

Aplicatia a fost dezvoltata in Python si rulata local ca mai jos:

Instalare librarii:

pip install -r requirements.txt

Rulare aplicatie:

py -3.10 -m streamlit run app.py

Aceasta aplicatie permite explorarea interactiva a datelor, vizualizarea relatiilor dintre variabile si construirea de modele predictive, contribuind astfel la intelegerea factorilor care influenteaza calitatea vinului.

1.2 Functia: incarca_date()

Descriere: Incarcarea datelor din fisier CSV

a) Definirea problemei: Incarcarea datasetului

b) Informatii necesare: WineQT.csv

c) Metode: pd.read_csv() din pachetul pandas

d) Rezultate: Datele sunt afisate in aplicatie sub forma de tabel

e) Interpretare economica: Permite analiza initiala a datelor si identificarea variabilelor relevante

1. Incarcarea datelor

Fisierul WineQT.csv a fost incarcat cu succes.

Numar randuri	Numar coloane	Valori lipsa initiale
1143	14	0

Primele 5 inregistrari - head()

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality	quality_label	quality_encoded
0	7.4	0.7	0	1.9	0.076	11	34	0.9978	3.51	0.56	9.4	5	Slab	0
1	7.8	0.88	0	2.6	0.098	25	67	0.9968	3.2	0.68	9.8	5	Slab	0
2	7.8	0.76	0.04	2.3	0.092	15	54	0.997	3.26	0.65	9.8	5	Slab	0
3	11.2	0.28	0.56	1.9	0.075	17	60	0.998	3.16	0.58	9.8	6	Slab	0
4	7.4	0.7	0	1.9	0.076	11	34	0.9978	3.51	0.56	9.4	5	Slab	0

1.3 Functia: trateaza_valori_lipsa()

Descriere: Eliminarea valorilor lipsa

a) Definirea problemei: Valori lipsa

b) Informatii necesare: Coloane numerice din datasetul WineQT.csv

c) Metode: isnull() pentru verificarea valorilor lipsa din pachetul pandas

d) Rezultate: Nu au fost identificate valori lipsa in dataset

e) Interpretare economica: Asigura obtinerea unor rezultate stabile si corecte in analiza datelor

3. Valori lipsa si valori extreme

Valori lipsa - isnull()

	Coloana	Numar valori lipsa
0	fixed acidity	0
1	volatile acidity	0
2	citric acid	0
3	residual sugar	0
4	chlorides	0
5	free sulfur dioxide	0
6	total sulfur dioxide	0
7	density	0
8	pH	0
9	sulphates	0

Prelucrare aplicata

- valorile lipsa numerice au fost completate cu mediana
- valorile extreme au fost tratate prin metoda IQR
- s-a creat variabila categoriala quality_label

1.4 Functia: trateaza_outlieri()

Descriere: Eliminarea valorilor extreme

a) Definirea problemei: Outlieri

b) Informatii necesare: Distributia datelor din datasetul WineQT.csv

c) Metode: metoda IQR utilizand functii din pachetele pandas si numpy

d) Rezultate: Date curate, fara influenta valorilor extreme

e) Interpretare economica: Permite obtinerea unor rezultate mai realiste in analiza calitatii vinului

Date dupa prelucrare

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality	quality_label	quality_encoded
0	7.4	0.7	0	1.9	0.076	11	34	0.9978	3.51	0.56	9.4	5	Slab	0
1	7.8	0.88	0	2.6	0.098	25	67	0.9968	3.2	0.68	9.8	5	Slab	0
2	7.8	0.76	0.04	2.3	0.092	15	54	0.997	3.26	0.65	9.8	5	Slab	0
3	11.2	0.28	0.56	1.9	0.075	17	60	0.998	3.16	0.58	9.8	6	Slab	0
4	7.4	0.7	0	1.9	0.076	11	34	0.9978	3.51	0.56	9.4	5	Slab	0

1.5 Functia: explorare_date()

Descriere: Statistici descriptive

a) Definirea problemei: Analiza datasetului

b) Informatii necesare: Datele din datasetul WineQT.csv

c) Metode: describe() si dtypes din pachetul pandas

d) Rezultate: Statistici descriptive ale variabilelor

e) Interpretare economica: Permite intelegerea caracteristicilor generale ale datelor si a distributiei acestora

2. Explorare date

Tipuri de date

	Coloana	Tip
3	residual sugar	float64
4	chlorides	float64
5	free sulfur dioxide	float64
6	total sulfur dioxide	float64
7	density	float64
8	pH	float64
9	sulphates	float64
10	alcohol	float64
11	quality	float64
12	quality_label	object

Statistici descriptive

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alco
count	1143	1143	1143	1143	1143	1143	1143	1143	1143	1143	1
mean	8.27	0.5299	0.2683	2.3231	0.0809	15.4633	45.1273	0.9967	3.3101	0.649	10.4
std	1.6302	0.1743	0.1964	0.6096	0.0178	9.7259	29.9748	0.0018	0.1518	0.1365	1.0
min	4.6	0.12	0	0.9	0.04	1	6	0.9922	2.9125	0.33	
25%	7.1	0.3925	0.09	1.9	0.07	7	21	0.9956	3.205	0.55	
50%	7.9	0.52	0.25	2.2	0.079	13	37	0.9967	3.31	0.62	
75%	9.1	0.64	0.42	2.6	0.09	21	61	0.9978	3.4	0.73	
max	12.1	1.0113	0.915	3.65	0.12	42	121	1.0013	3.6925	1	

Selectarea unei coloane

Exemplu:

```
df['alcohol'].head()
```

	alcohol
0	9.4
1	9.8
2	9.8
3	9.8
4	9.4

Exemplu loc / iloc

```
df.iloc[0:5, 0:4]
```

	fixed acidity	volatile acidity	citric acid	residual sugar
0	7.4	0.7	0	1.9
1	7.8	0.88	0	2.6
2	7.8	0.76	0.04	2.3
3	11.2	0.28	0.56	1.9
4	7.4	0.7	0	1.9

1.6 Functia: grupare_date()

Descriere: Grupare si agregare

a) Definirea problemei: Compararea datelor in functie de nivelul de calitate

b) Informatii necesare: Variabila quality din datasetul WineQT.csv

c) Metode: groupby() si mean() din pachetul pandas

d) Rezultate: Medii ale variabilelor pentru fiecare nivel de calitate

e) Interpretare economica: Permite compararea caracteristicilor vinurilor in functie de calitate

Obiectiv: analiza caracteristicilor chimice ale vinului si construirea unor modele care explica sau estimeaza nivelul calitatii.

4. Grupare si agregare

Media indicatorilor pe niveluri de calitate

```
df.groupby('quality').mean(numeric_only=True)
```

quality	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality_encoded
3.5	8.45	0.8027	0.2117	2.325	0.0892	8.3667	24.5	0.9977	3.3617	0.55	9.6917	0
4	7.797	0.6962	0.1632	2.3742	0.079	14.9485	40.6061	0.9967	3.3884	0.6815	10.2606	0
5	8.1253	0.5834	0.2401	2.3181	0.0843	16.3602	54.3758	0.9971	3.3021	0.6048	9.8994	0
6	8.2868	0.5049	0.2637	2.2837	0.08	15.1331	39.6623	0.9966	3.3219	0.6684	10.6508	0
7	8.7497	0.3937	0.3866	2.45	0.0739	14.4406	35.2168	0.9961	3.2864	0.7381	11.4766	1
7.5	8.775	0.41	0.4325	2.375	0.0702	11.0625	29.375	0.9956	3.2409	0.76	11.9063	1

Numarul observatiilor pe fiecare nivel de calitate

	Calitate	Numar observatii
0	3.5	6
1	4	33
2	5	483
3	6	462
4	7	143
5	7.5	16

1.7 Functia: grafice()

Descriere: Vizualizare date

a) Definirea problemei: Reprezentarea grafica a datelor

b) Informatii necesare: Variabilele din datasetul WineQT.csv

c) Metode: functii din pachetul matplotlib, integrate in Streamlit

d) Rezultate: Grafice pentru distributia calitatii si relatia dintre variabile

e) Interpretare economica: Permite identificarea tendintelor si a relatiilor dintre indicatori

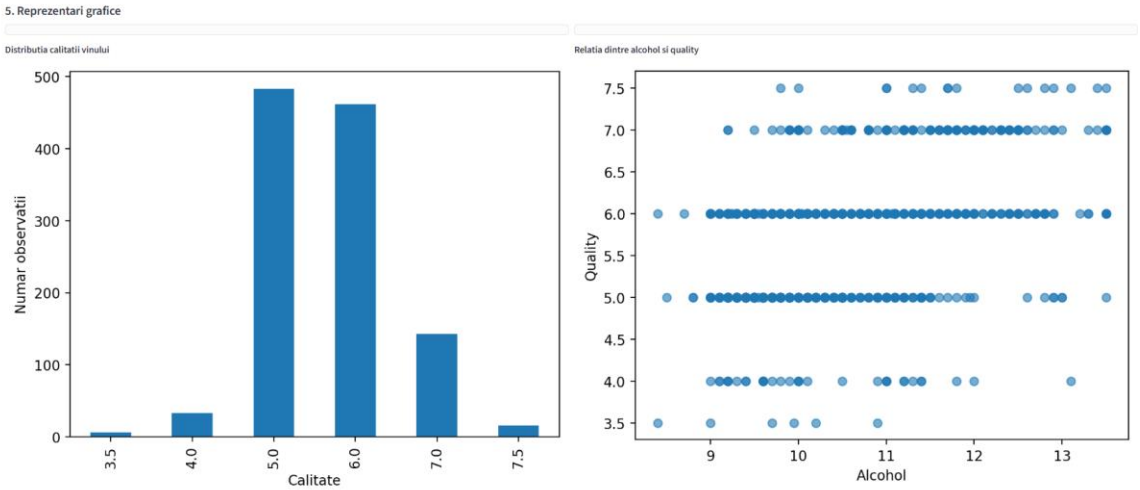

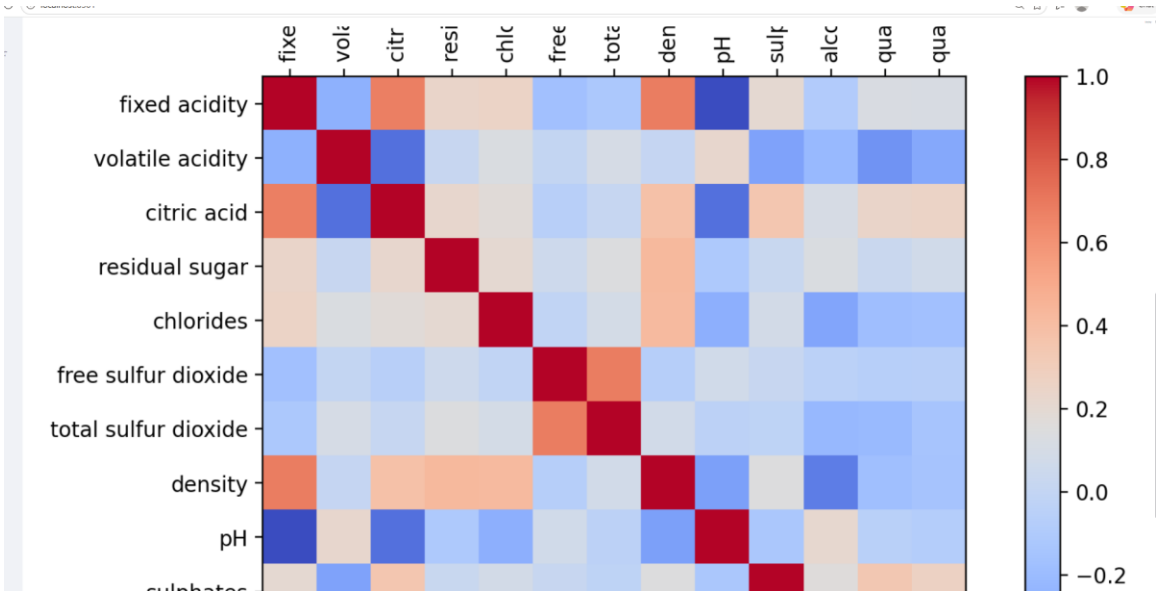

1.8 Etapa: codificare_date()

Descriere: Codificare variabile

a) Definirea problemei: Transformarea variabilei quality in format categorial si numeric

b) Informatii necesare: Variabila quality din datasetul WineQT.csv

c) Metode: np.where() din pachetul numpy si map() din pachetul pandas

d) Rezultate: Date codificate in variabilele quality_label si quality_encoded

e) Interpretare economica: Permite separarea vinurilor in functie de calitate si utilizarea lor in modele predictive

1. Incarcarea datelor

Fisierul WineQT.csv a fost incarcat cu succes.

Numar randuri	Numar coloane	Valori lipsa initiale
1143	14	0

Primele 5 inregistrari - head()

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality	quality_label	quality_encoded
0	7.4	0.7	0	1.9	0.076	11	34	0.9978	3.51	0.56	9.4	5	Slab	0
1	7.8	0.88	0	2.6	0.098	25	67	0.9968	3.2	0.68	9.8	5	Slab	0
2	7.8	0.76	0.04	2.3	0.092	15	54	0.997	3.26	0.65	9.8	5	Slab	0
3	11.2	0.28	0.56	1.9	0.075	17	60	0.998	3.16	0.58	9.8	6	Slab	0
4	7.4	0.7	0	1.9	0.076	11	34	0.9978	3.51	0.56	9.4	5	Slab	0

1.9 Etapa: scalare_date()

Descriere: Normalizare date

a) Definirea problemei: Scalarea variabilelor numerice

b) Informatii necesare: Variabilele numerice din datasetul WineQT.csv

c) Metode: StandardScaler() din pachetul scikit-learn

d) Rezultate: Date scalate, cu valori normalizate

e) Interpretare economica: Permite compararea corecta intre variabile si imbunatateste performanta modelelor predictive

Scalarea datelor

```
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxic
0	-0.5339	0.9766	-1.3665	-0.6944	-0.2776	-0.4591	-0.371
1	-0.2884	2.0099	-1.3665	0.4544	0.9622	0.981	0.7
2	-0.2884	1.321	-1.1627	-0.038	0.6241	-0.0477	0.296
3	1.7981	-1.4345	1.4857	-0.6944	-0.3339	0.1581	0.496
4	-0.5339	0.9766	-1.3665	-0.6944	-0.2776	-0.4591	-0.371

1.10 Functia: sectiune_clasificare()

Descriere: Clasificare vinuri

a) Definirea problemei: Predictia calitatii vinurilor

b) Informatii necesare: Datele scalate si variabila quality_encoded din datasetul WineQT.csv

c) Metode: LogisticRegression() din pachetul scikit-learn

d) Rezultate: Acuratetea modelului si matricea de confuzie

e) Interpretare economica: Permite clasificarea vinurilor in functie de calitate si sprijina luarea deciziilor privind controlul calitatii

Analiza calitatii vinului folosind Streamlit, Pandas, Scikit-learn si Statsmodels

Obiectiv: analiza caracteristicilor chimice ale vinului si construirea unor modele care explica sau estimeaza nivelul calitatii.

6. Clasificare - Regresie logistica

Acuratete

Accuracy

86.46%

Scalarea datelor

```
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol
0	-0.5339	0.9766	-1.3665	-0.6944	-0.2776	-0.4591	-0.3714	0.5836	1.3175	-0.6524	-0.9716
1	-0.2884	2.0099	-1.3665	0.4544	0.9622	0.981	0.73	0.0408	-0.7257	0.2273	-0.5971
2	-0.2884	1.321	-1.1627	-0.038	0.6241	-0.0477	0.2961	0.1493	-0.3302	0.0074	-0.5971
3	1.7981	-1.4345	1.4857	-0.6944	-0.3339	0.1581	0.4964	0.6921	-0.9894	-0.5058	-0.5971
4	-0.5339	0.9766	-1.3665	-0.6944	-0.2776	-0.4591	-0.3714	0.5836	1.3175	-0.6524	-0.9716

Raport de clasificare

	precision	recall	f1-score	support
0	0.90	0.95	0.92	197
1	0.53	0.31	0.39	32
accuracy			0.86	229
macro avg	0.71	0.63	0.66	229
weighted avg	0.84	0.86	0.85	229

1.11 Functia: sectiune_regresie()

Descriere: Regresie multipla

a) Definirea problemei: Determinarea influentei variabilelor asupra calitatii vinului

b) Informatii necesare: Variabilele numerice si variabila quality din datasetul WineQT.csv

c) Metode: OLS() din pachetul statsmodels

d) Rezultate: Coeficientii modelului si indicatori statistici (R-squared, p-values)

e) Interpretare economica: Permite identificarea factorilor care influenteaza calitatea vinului si sprijina optimizarea procesului de productie

7. Regresie multipla - Statsmodels

Rezumatul modelului

```
OLS Regression Results
==============================================================================
Dep. Variable:           quality   R-squared:                       0.389
Model:                        OLS   Adj. R-squared:                  0.383
Method:             Least Squares   F-statistic:                     65.55
Date:            Sun, 19 Apr 2026   Prob (F-statistic):          5.19e-113
Time:                    14:03:06   Log-Likelihood:                -1054.5
No. Observations:            1143   AIC:                             2133.
Df Residuals:                1131   BIC:                             2194.
Df Model:                      11
Covariance Type:        nonrobust
==========================================================================================
                             coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------------------
const                     27.3774     26.252      1.043      0.297     -24.132      78.886
fixed acidity              0.0467      0.030      1.530      0.126      -0.013       0.106
volatile acidity          -1.0968      0.138     -7.971      0.000      -1.367      -0.827
citric acid               -0.3131      0.160     -1.952      0.051      -0.628       0.002
residual sugar             0.0263      0.042      0.627      0.531      -0.056       0.109
chlorides                 -2.2665      1.184     -1.915      0.056      -4.589       0.056
free sulfur dioxide        0.0032      0.003      1.207      0.228      -0.002       0.008
total sulfur dioxide      -0.0029      0.001     -3.208      0.001      -0.005      -0.001
density                  -23.7546     26.795     -0.887      0.376     -76.328      28.819
pH                        -0.3421      0.216     -1.585      0.113      -0.766       0.081
sulphates                  1.1953      0.153      7.813      0.000       0.895       1.495
alcohol                    0.2676      0.032      8.364      0.000       0.205       0.330
==============================================================================
Omnibus:                       10.150   Durbin-Watson:                   1.776
Prob(Omnibus):                  0.006   Jarque-Bera (JB):               10.746
Skew:                          -0.183   Prob(JB):                      0.00464
Kurtosis:                       3.303   Cond. No.                     1.20e+05
==============================================================================
```